

IA vs. codificação manual

Um experimento controlado com 18 trials de katas em Java

MOTIVAÇÃO

Muito relato sobre IA, pouca medição controlada

RQ1 • Tempo

A IA reduz o tempo para resolver a tarefa?

Tempo até todos os testes passarem

RQ2 • Defeitos

A IA reduz os testes que falham?

Testes falhando e taxa de sucesso

RQ3 • Estrutura

A IA altera complexidade ou duplicação?

PMD, CPD e LOC como controle

DESENHO DO EXPERIMENTO

Cada pessoa comparada consigo mesma

3

participantes

6

katas autorais em Java 21

18

trials: 9 com IA, 9 sem IA

35'

time-box fixo por trial

Crossover within-subject

Cada um resolve 3 katas com IA e 3 sem, com distribuição contrabalanceada (2:1 por kata).

Mesmo assistente

Claude Sonnet 5, esforço High, nova conversa por trial e prompt inicial padronizado.

8 testes de aceitação

JUnit 5, iguais para todos, visíveis desde o início e sem permissão de alteração.

OBJETOS EXPERIMENTAIS

Seis katas autorais, pouco indexados

kata-01

Normalizador de Etiquetas

Normalizar e deduplicar strings

kata-02

Agrupador de Extrato

Somar por categoria e ordenar

kata-03

Compressor de Corridas

Run-length com regra própria

kata-04

Validador de Agenda

Sobreposição de horários

kata-05

Mascarador de Contatos

Validar e mascarar e-mail/telefone

kata-06

Encadeador de Trechos

Itinerários com detecção de ciclos

COLETA AUTOMATIZADA

Do trial ao dashboard sem cronômetro manual



Tudo roda na mesma imagem **Docker** com versões fixadas: Java 21, Maven, JUnit 5, PMD 7.17 e Python 3.12 com pandas, SciPy e seaborn.

RQ1 · TEMPO

Mediana sem IA

820 s




Mediana com IA

222 s

Com IA, a mediana de tempo foi cerca de 3,7× menor

RQ1 · POR PARTICIPANTE

Os três foram mais rápidos com IA



Mediana	Sem IA	Com IA
Gabriel	238,7 s	183,2 s
Joaquim	999,1 s	290,7 s
Vitor	1163,7 s	99,6 s

Efeito máximo, mas sem significância: por quê?

Wilcoxon pareado, unilateral

$W = 0$

Nenhum par a favor do sem IA

p-valor

0,125

Não significativo a $\alpha = 0,05$

Tamanho de efeito (rank-biserial)

-1,00

Máximo possível: todos na mesma direção



Com 3 pares, o menor p possível é $1/2^3 = 0,125$. Nenhum resultado poderia ser significativo: a direção é forte e uniforme, mas não confirmável.

No final, empate. No caminho, diferença.

Código final

18/18


trials com 8/8 testes passando, nos dois tratamentos. Sem variação, o Wilcoxon não se aplica.

Execuções dos testes até o verde

	Com IA	Sem IA
Gabriel	1, 1, 1	1, 1, 1
Joaquim	1, 1, 1	2, 3, 5
Vitor	1, 1, 1	3, 5, 7

Todos os 9 trials com IA passaram na primeira execução.

Mais rápido não significou código pior



Mediana	Sem IA	Com IA
Complexidade	8,33	7
LOC	47	38
Duplicação	0%	0%
p (bilateral)	0,75	1,00

Três jeitos diferentes de usar a mesma IA

Gabriel

IA como solucionadora

Enunciado completo; no kata-02, a implementação veio pronta e ficou verde em 43 s.

Joaquim

IA guiada passo a passo

4 a 5 instruções por kata; ele decompôs o problema e a IA escreveu cada parte.

Vitor

Proposta, aprovação, escrita

Um ciclo só nos katas 01 e 03 (21 s no mais rápido); no kata-05, 7 decisões discutidas e 410 s.

Em todos os estilos a IA acertou as regras de primeira; o tempo dependeu mais de **quanto se deliberou** do que do kata.

AMEAÇAS À VALIDADE

O que limita as conclusões

Ameaça	Como lidamos
Poder estatístico (n = 3)	Principal limitação: p mínimo de 0,125; resultados exploratórios, com tamanho de efeito
Contrabalanceamento 2:1	Em cada kata, o tratamento coincide com o participante; comparação por kata só descritiva
Memorização pela IA	Katas autorais, com regras e formatos de entrada próprios
Autor dos katas participou	Gabriel teve o menor ganho com IA; considerado na leitura

CONCLUSÃO

Mais rápido, sem ficar pior

- RQ1** A IA reduziu o tempo para os três participantes; hipótese apoiada pela direção dos dados, sem significância formal.
- RQ2** Corretude final igual (8/8 em todos); com IA, menos tentativas até o verde.
- RQ3** Sem diferença estrutural detectável em complexidade, duplicação ou LOC.

Próximo passo: mais participantes para ter poder estatístico real, e katas maiores para a estrutura variar.

Obrigado! Perguntas?

Repositório, dados, scripts e relatório completo:

github.com/lab-medicao-experimentacao/lab02-ia-vs-manual